



Café com Dados & Gatos

Data Science & IA, com didática e sem enrolação



VÍDEOS NOVOS
TODAS AS SEMANAS

INSCREVA-SE

Preços por empresa

Pesquisa de aluguel de GPU por hora para IA generativa Café com Dados & Gatos - ComfyUI,
Stable Diffusion, Flux e IA generativa

Como ler este documento

Este documento reúne os preços coletados por empresa. Ele não é um ranking final: é a base de pesquisa. Mantive moedas originais quando o provedor usa euro e preservei observações sobre compromisso, spot, recursos extras e limitações.

Critério principal da pesquisa: 1 GPU, on-demand quando disponível, foco em GPUs úteis para geração de imagem e IA generativa. Multi-GPU, cluster, compromisso mínimo e preço sob consulta ficam marcados como observação.

Salad

Tipo de cobrança/perfil: GPU cloud / containers, preço por hora

Preços variam conforme prioridade e configuração. A tabela Batch usa 8GB RAM e 4 vCPU. Custo final depende do tempo em que o container roda.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
RTX 5090	32GB	\$0.25/h no calculator; \$0.294/h Batch	1 GPU replica	Prioridade/configuração muda preço
RTX 4090	24GB	\$0.16/h no calculator; \$0.204/h Batch	1 GPU replica	Muito competitivo para ComfyUI/Flux
RTX 5080	16GB	\$0.18/h; \$0.219/h Batch	1 GPU replica	Boa opção intermediária
RTX 4080	16GB	\$0.11/h; \$0.154/h Batch	1 GPU replica	Preço baixo, menos VRAM
RTX 5070 Ti	16GB	\$0.10/h	1 GPU replica	Opção barata
RTX 5060 Ti	16GB	\$0.07/h	1 GPU replica	Entrada moderna, cuidado com VRAM/workflow
RTX A5000	24GB	\$0.09/h	1 GPU replica	Preço muito baixo para 24GB

Vast.ai

Tipo de cobrança/perfil: Marketplace, preços ao vivo por hora

Mostra preço ao vivo e faixa de variação. Pode mudar muito por host, região, specs, disponibilidade e confiabilidade do provedor.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
RTX 5090	32GB	\$0.40/h	High availability	Faixa \$0.21-\$53.33/h
RTX 4090	24GB	\$0.34/h	High availability	Faixa \$0.13-\$2.75/h
L40S	48GB	\$0.47/h	Medium availability	Faixa \$0.40-\$1.20/h
RTX 6000 Ada	48GB	\$0.59/h	Low availability	Faixa \$0.39-\$1.00/h
A100 PCIe	80GB	\$0.49/h	Medium availability	Faixa \$0.40-\$1.42/h
A100 SXM4	80GB	\$0.78/h	Medium availability	Faixa \$0.40-\$1.57/h

H100 NVL	94GB	\$1.99/h	Low availability	Faixa \$1.33-\$4.67/h
H100 SXM	80GB	\$2.00/h	Low availability	Faixa \$1.33-\$5.03/h
H200 NVL	141GB	\$2.88/h	Low availability	Faixa \$1.35-\$8.00/h
H200	141GB	\$3.50/h	Low availability	Faixa \$1.32-\$7.89/h
B200	192GB	\$5.00/h	Low availability	Faixa \$4.16-\$5.88/h
B300	288GB	\$6.25/h	Low availability	Faixa \$5.63-\$6.69/h

Massed Compute

Tipo de cobrança/perfil: On-demand, preço por hora, 1x a 8x GPU

Preços oficiais para configurações x1 GPU. Bare metal e commitment pricing sob contato.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
A30	24GB	\$0.35/h	16 vCPU, 48GB RAM, 256GB storage	Entrada/baixo custo
RTX A5000	24GB	\$0.44/h	10 vCPU, 32GB RAM, 256GB storage	Entrada 24GB
RTX A6000	48GB	\$0.55-\$0.57/h	6 vCPU, 32-96GB RAM, 256-300GB storage	48GB barato
RTX 6000 Ada	48GB	\$0.79/h	12 vCPU, 72GB RAM, 350GB storage	Excelente custo/48GB
L40	48GB	\$0.86/h	14 vCPU, 72GB RAM, 625GB storage	48GB profissional
L40S	48GB	\$0.88/h	12 vCPU, 72GB RAM, 625GB storage	Boa para IA generativa
A100	80GB	\$1.35/h	16 vCPU, 96GB RAM, 512GB storage	VRAM alta
A100 SXM4	80GB	\$1.38/h	14 vCPU, 100GB RAM, 625GB storage	SXM4, VRAM alta
DGX A100	80GB	\$1.38/h	16 vCPU, 120GB RAM, 1000GB storage	A100/DGX
H100	80GB	\$2.73/h	20 vCPU, 128GB RAM, 1250GB storage	Premium
H100 NVL	94GB	\$3.11/h	18 vCPU, 128GB RAM, 750GB storage	Premium/NVL

H200 NVL	141GB	\$3.62/h	16 vCPU, 180GB RAM, 750GB storage	Enterprise
RTX PRO 6000 Blackwell	96GB	\$2.19/h	16 vCPU, 144GB RAM, 725GB storage	Blackwell/96GB

ThunderCompute

Tipo de cobrança/perfil: On-demand, cobrado por minuto

Primeiros 100GB de storage incluídos; storage adicional, snapshots e vCPU adicional são cobrados separadamente.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
RTX A6000	48GB	\$0.35/h	6-8 vCPU, 48-64GB RAM, 100-500GB disk	Muito barato para 48GB
L40	48GB	\$0.79/h	6-12 vCPU, 48-96GB RAM, 100-500GB disk	48GB profissional
A100	80GB	\$1.09/h	8-16 vCPU, 64-128GB RAM, 100-500GB disk	Boa opção 80GB
H100 PCIe	80GB	\$2.19/h	4-16 vCPU, 32-128GB RAM, 100-500GB disk	H100 barato no recorte

VERDA

Tipo de cobrança/perfil: On-demand / pay-as-you-go; spot separado

Tem spot, mas a comparação principal usa on-demand. Storage NVMe separado informado em outra coleta: \$0.20/GiB/mês.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
RTX A6000	48GB	\$0.61/h	10 CPU, 60GB RAM	48GB entrada
RTX 6000 Ada	48GB	\$1.04/h	10 CPU, 60GB RAM	48GB profissional
L40S	48GB	\$1.37/h	20 CPU, 60GB RAM	IA generativa/pro
A100 SXM4	40GB	\$1.29/h	22 CPU, 120GB RAM	A100 40GB
A100 SXM4	80GB	\$1.79/h	22 CPU, 120GB RAM	A100 80GB
H100 SXM5	80GB	\$3.25/h	30-32 CPU, 120-185GB RAM	Premium
H200 SXM5	141GB	\$4.00/h	44 CPU, 182GB RAM	Enterprise
B200 SXM6	180GB	\$6.11/h	30 CPU, 170GB RAM	Blackwell

B300 SXM6	268GB	\$7.50/h	30 CPU, 255GB RAM	Blackwell
GB300 SXM6	288GB	\$8.62/h	32 CPU, 225GB RAM	Blackwell/enterprise
RTX PRO 6000	96GB	\$1.89/h	30 CPU, 90GB RAM	96GB pro

Radiant / Ori

Tipo de cobrança/perfil: Por minuto / por hora; recursos separados

GPU tem preço público, mas memória, CPU e load balancer também podem ser cobrados separadamente. Perfil técnico/Kubernetes.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
L4	24GB	\$1.14/h	SKU ogx-k8s-l4	GPU mais barata na tabela Ori
L40S	48GB	\$2.09/h	SKU ogx-k8s-l40s	Mais interessante para IA generativa que H100/H200
H100	80GB	\$3.92/h	SKU ogx-k8s-h100	Premium
H100 SXM	80GB	\$3.92/h	SKU ogx-k8s-h100sxm-80	Premium/SXM
H200 SXM	141GB	\$4.725/h	SKU ogx-k8s-h200sxm-141	Enterprise

DigitalOcean

Tipo de cobrança/perfil: GPU Cloud / Dedicated GPUs, preço por hora

Atenção: alguns preços exibidos são para compromisso de 3 anos. H100 on-demand promocional informado: \$5.95/h.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
A4000	?	\$0.76/h	45GB RAM, 8 vCPU	Menos foco para genAI atual
A6000	?	\$1.89/h	45GB RAM, 8 vCPU	48GB/pro
GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
A5000	?	\$1.38/h	45GB RAM, 8 vCPU	24GB/pro
A100	80GB	\$1.15/h com 3 anos	90GB RAM, 12 vCPU	Não usar como on-demand puro

H100	80GB	\$5.95/h on-demand promo; \$2.24/h com 3 anos	256GB RAM, 20 vCPU	Distinguir compromisso vs on-demand
------	------	--	--------------------	-------------------------------------

Scaleway

Tipo de cobrança/perfil: GPU Instances, preço em euro por hora

Coleta em PAR-1. L40S/H100 estavam disponíveis em PAR-2, mas sem preço copiado nesse trecho.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
L4	24GB	€0.79/h	8 vCPU, 48GB RAM, block storage, 2.5Gbps	Preço oficial visível
L40S	48GB	Preço não copiado	8 vCPU, 96GB RAM; disponível em PAR-2	Pendente
H100	80GB	Preço não copiado	24 vCPU, 240GB RAM; disponível em PAR-2	Pendente

LeaderGPU

Tipo de cobrança/perfil: Bare-metal / servidores dedicados; preço em euro

Sem VAT. Pedido mínimo de €10. Em pagamento por minuto/hora, tráfego incluído para internet aparece como 0GB; adicional €0.09/GB.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
RTX 5090	32GB	€2.40/h	1 GPU, 128GB RAM, 960GB SSD	1 hora coletada
RTX A6000	48GB	€2.40/h	1 GPU, 128GB RAM, 480GB SSD	1 hora coletada
RTX 4090	24GB	€59.90/dia	1 GPU, 512GB RAM, 960GB SSD	Não usar como preço/h direto
RTX 6000 Ada	48GB	€6.00/h total	4 GPUs	Fora do filtro 1 GPU
A100	40GB	€7.20/h total	8 GPUs	Fora do filtro 1 GPU

Lambda Labs

Tipo de cobrança/perfil: Clusters com compromisso mínimo no trecho coletado

Trecho coletado era de HGX/cluster, não instância simples 1x GPU on-demand. Entrar como enterprise/cluster neste documento.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
HGX B200	B200	\$9.86/GPU/h	16 GPUs, 2 semanas-1 ano	Cluster
HGX B200	B200	\$9.36/GPU/h	64 GPUs, 2 semanas-1 ano	Cluster
GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
HGX B200	B200	\$8.87/GPU/h	256+ GPUs, 2 semanas-1 ano	Cluster
H100	80GB	\$6.16/GPU/h	16 GPUs, 2 semanas-1 ano	Cluster
H100	80GB	\$5.85/GPU/h	64 GPUs, 2 semanas-1 ano	Cluster
H100	80GB	\$5.54/GPU/h	256 GPUs, 2 semanas-1 ano	Cluster

Vultr

Tipo de cobrança/perfil: Cloud GPU - validação oficial incompleta

Página enviada, mas sem cópia de tabela. No recorte anterior apareceu GH200 a \$1.99/GPU/h pelo agregador. Marcar como pendente de confirmação oficial.

GPU/modelo	VRAM	Preço coletado	Configuração/host	Observação
GH200 Grace Hopper	96GB	\$1.99/GPU/h visto no agregador	72 vCPU, 480GB RAM, 960GB storage, Atlanta	Pendente validar no site oficial